

DAY 1 / MODEL DESIGN

초기 방전 곡선으로 배터리 수명 예측하기

Batch1~3 비교 EDA와 머신러닝 모델 설계 전략

울산캠퍼스 3반 | 최병준 | 2026.10.01

139개

전체 셀

129개

수명 확인 셀

100사이클

예측 시점

핵심 결론

- Batch2는 단수명 비율이 71.8%이고 꺾임 후보도 가장 일찍 나타납니다. 배치별 운전 조건을 함께 살펴봐야 합니다.
- 초기 $\Delta Q(V)$ 분산과 수명은 세 배치 모두 음의 관계입니다. 현재 가장 일관된 초기 예측 변수로 선택합니다.
- 수명을 숫자로 예측하는 회귀를 선택합니다. 첫 후보는 Random Forest, 비교 기준은 Ridge로 둡니다.

데이터와 분석 단위

배치 / 원본 날짜	전체 / 수명 확인	수명 결측
Batch1 / 2017-05-12	46 / 46	0
Batch2 / 2018-02-20	47 / 39	8
Batch3 / 2018-04-12	46 / 44	2

한 행은 한 셀입니다. 배치 안에서 cell_id가 반복되므로 (batch, cell_id)로 구분합니다. cell metadata, cycle summary, 보관 profile, 공통 전압 측 네 종류의 저장 데이터를 사용했습니다.

보고서 읽는 순서

질문 1~5마다 그래프의 핵심 관찰, 해석, 모델 설계에 반영할 점을 연결합니다. 마지막에 Feature Engineering과 후보 모델을 정리합니다.

EDA / QUESTION 01

수명 분포는 배치마다 얼마나 다른가?




그림 1. 150~2300사이클의 동일 구간·축으로 비교했습니다. 점선은 각 배치 중앙값입니다. 실제 관측 수명 범위는 392~1935사이클입니다.




그림 2. 비율의 분모는 수명값이 있는 셀입니다. 단수명 <500, 장수명 >1000, 중간 수명 500~1000으로 구분했습니다.

배치	중앙값	관측 범위	단수명 / 장수명
Batch1	858.5	534~1227	0 / 10
Batch2	472.0	392~1186	28 / 3
Batch3	1005.5	541~1935	0 / 23

해석: Batch2의 짧은 수명은 일부 극단값만의 문제가 아니다

단수명 28개가 모두 Batch2에 있고, 해당 배치의 71.8%를 차지합니다. Batch2의 기본 운전 그룹은 30개 중 28개가 단수명인 반면 newstructure 9개에서는 단수명이 없습니다. 가장 짧은 셀은 Batch2 cell 20(392사이클)입니다. 이를 단순 오류로 판단해 제거하지 않습니다.

모델 설계에 반영

배치 차이를 무시한 무작위 분할은 실제 다른 배치에서의 어려움을 가릴 수 있습니다. 배치별 검증과 수명 구간별 오차를 함께 보고, 특정 배치에만 있는 단수명 그룹을 곧바로 분류 문제로 고르지 않습니다.

EDA / QUESTION 02

열화는 일정한가, 후반에 빨라지는가?




그림 3. 흐린 선은 수명 확인 셀, 굵은 선은 배치 수명 중앙값과 가까운 대표 셀입니다. Q10으로 정규화하고 0.76~1.10 구간을 확대했습니다. 범위 밖 값을 원본에서 제거한 것은 아닙니다. 대표 선은 21점 중앙값, 점선은 꺾임 후보입니다.

배치	안정적 꺾임 후보 / 확인 셀	중앙 시점	후보 범위
Batch1	45 / 46	634.0	422~980
Batch2	38 / 39	360.5	246~949
Batch3	44 / 44	826.5	382~1533

해석: Batch2는 열화 가속이 더 일찍 나타난다

각 배치에서 초반의 완만한 변화 뒤 후반의 빠른 용량 감소가 관찰됩니다. 같은 진단 규칙을 적용한 꺾임 후보의 중앙 시점은 Batch1 634, Batch2 361, Batch3 827사이클입니다. Batch2의 짧은 수명 분포와 이른 가속 시점이 함께 나타납니다. 다만 서로 다른 운전 조건을 가진 셀들의 비교입니다.

방법: 100사이클 이후에 이어 붙인 두 직선을 적합했습니다. 11·21·41점 중앙값에서 모두 후보가 발견되고 위치 차이가 20사이클 이하면 안정적 후보로 표시했습니다. 구간당 최소 50점, 직선 대비 오차 감소 10% 이상 조건을 사용했습니다. 물리적 원인이나 확정된 knee를 뜻하지 않습니다.

모델 설계에 반영

최종 용량 감소와 후기 꺾임은 수명 설명용 EDA에만 사용합니다. 초기 100사이클 예측 모델에는 꺾임 위치, 마지막 cycle, 전체 기록 길이를 넣지 않습니다.

EDA / QUESTION 03

초기 $\Delta Q(V)$ 가 이후 수명을 구분하는가?

$\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$. 같은 1000점 전압축(3.5→2.0 V)에서 계산합니다. $\Delta Q(V)$ 는 용량 차이 곡선이며, 미분 곡선 dQ/dV 와 구분합니다.




그림 4. 장수명·단수명 그룹의 $\Delta Q(V)$ 중앙 곡선입니다. Batch1·3에는 단수명 셀이 없어 해당 곡선을 그리지 않았습니다. Batch2 장수명은 3개뿐입니다.




그림 5. 전압별 차이의 분산에 log10을 적용한 값과 수명입니다. 색은 단수명/중간/장수명이며 점선은 500·1000 기준입니다.

해석: 초기 변화의 크기와 모양이 수명 정보와 연결된다

$\log_{10} \Delta Q(V)$ 분산-수명 Pearson은 전체 -0.851, Batch1 -0.886, Batch2 -0.902, Batch3 -0.702입니다. 분산이 큰 셀일수록 수명이 짧은 방향이 배치 안에서도 나타납니다. 양쪽 수명 그룹만 고르면 -3.823 부근에서 나뉘지만, 중간 수명 65개를 빼고 본 결과입니다.

모델 설계에 반영

첫 입력은 $\log_{10}(\text{var}(\Delta Q(V)))$ 하나로 둡니다. 전체 수명이 연속적으로 달라지고 중간 셀도 많아, 경계 하나로 나누는 분류보다 수명 숫자를 예측하는 회귀를 우선합니다.

EDA / QUESTION 04

C-rate만으로 수명 차이를 설명할 수 있는가?




그림 6. Batch2의 공통 숫자 충전 정책 3개에서 평균 수명을 비교했습니다. 막대의 n은 정책·운전 그룹별 수명 확인 셀 수입니다.




그림 7. First C-rate와 수명의 관계입니다. Batch1에서는 음의 방향이지만 Batch2·3에서는 같은 단순 규칙이 유지되지 않습니다.

해석: 숫자 충전 조건이 같아도 운전 그룹 차이가 크다

공통 정책 3개에서 기본/newstructure 평균 수명은 각각 484/872, 478/962, 449/991사이클입니다. 첫 충전 전류만으로 이 차이를 설명하기 어렵습니다. Batch2 기본/새 그룹의 cycle 10 쉬는 시간 중앙값도 약 9.847/0.313분으로 달랐습니다. newstructure를 배터리 물리 구조 변경의 증거로 단정하지 않습니다.

First C-rate와 꺾임 이후 용량 감소 속도의 Pearson은 Batch1 +0.542(n=45), Batch2 +0.112(n=38), Batch3 +0.458(n=44)입니다. 배치 차이가 있고 후기 통계이므로 충전 전류의 원인 효과나 초기 예측 성능으로 해석하지 않습니다.

모델 설계에 반영

First C-rate, Switch SOC, Second C-rate는 조합으로 검토합니다. 초기 곡선 변수에 충전 조건을 더했을 때 개선되는지 비교하고, 같은 정책 안의 편차와 운전 그룹 차이를 함께 확인합니다.

각 배치의 프로토콜별 평균 수명 범위

배치	평균 수명이 가장 낮은 정책	평균 수명이 가장 높은 정책
Batch1	5.4C(80%)-5.4C (기본) / 546.5 / n=2	4C(80%)-4C (기본) / 1226.5 / n=2
Batch2	3.6C(9%)-5C (기본) / 394.5 / n=2	5.6C(26%)-4.5C (새 방식) / 991.3 / n=3
Batch3	3.7C(31%)-5.9C (새 방식) / 660.0 / n=3	4.8C(80%)-4.8C (새 방식) / 1564.2 / n=6

표의 수명 단위는 사이클입니다. 정책·운전 그룹별 평균의 양끝을 요약했습니다. n=2~6의 작은 표본이므로 최고 정책을 확정하는 순위로 해석하지 않습니다.

EDA / QUESTION 05

어떤 초기 신호가 유용하며, 무엇이 중복인가?




그림 8. 수명 확인 셀만 사용한 Pearson 상관입니다. 전체 상관뿐 아니라 배치 안의 방향을 함께 봅니다. IR=0은 유지했습니다.

해석: 크기보다 배치별 일관성이 중요하다

$\Delta Q(V)$ 관련 통계는 모든 배치에서 수명과 같은 방향입니다. 반면 충전시간의 상관은 Batch1 +0.739, Batch2 -0.902, Batch3 +0.644로 뒤집힙니다. 전체 상관만 보고 공통 효과가 있다고 판단하기 어렵습니다. Batch2 분산-수명 관계도 기본 그룹 안에서는 -0.386, 새 그룹 안에서는 -0.294로 약해져 조건 차이가 섞여 있습니다.

중복 변수	근거	Feature Engineering 결정
$\Delta Q(V)$ 분산·최솟값·평균·표준편차	서로 $ r $ 약 0.938~0.994	처음에는 log 분산 하나로 대표
Q10, Q100, Q100-Q10	Q10-Q100 $r=0.959$; 정확한 합 관계	선형모델에 세 개를 모두 넣지 않음
초기 평균·최대 온도	$r=0.894$	하나를 대표로 선택 후 추가 효과 검증

모델 설계에 반영

지금은 입력 하나여서 다중공선성 문제가 없습니다. 변수를 늘릴 때 중복 통계를 줄이고, 변수 선택은 학습용 데이터 안에서 결정합니다. 상관은 원인 입증이나 최종 예측 성능을 뜻하지 않습니다.

MODEL STRATEGY / 01

회귀 target과 입력 변수를 어떻게 정할 것인가?

선택한 문제

처음 100사이클을 관측한 뒤, 전체 수명 cycle_life를 숫자로 예측합니다. 학습 target은 $\log_{10}(\text{cycle_life})$, 예측값을 사이클 단위로 되돌린 뒤 MAPE(%)로 평가합니다. MAE·RMSE·R²와 수명 구간별 오차도 함께 봅니다.

Regression을 선택한 이유

단수명 28개·장수명 36개만 나누면 중간 수명 65개를 제외하게 됩니다. 1000 초과/이하 분류는 전체 셀을 포함할 수 있지만, 그 경계가 자연스럽게 떨어지는 공통 규칙은 뚜렷하지 않습니다. 수명 숫자를 예측하는 목적에 맞춰 회귀 하나를 선택합니다.

Feature Engineering 계획

구분	변수 / 처리	EDA에서 나온 이유
첫 모델 입력	$\log_{10}(\text{var}(Q100(V)-Q10(V)))$	배치 안에서도 일관된 음의 관계
추가 비교 후보	초기 Q10과 용량 변화, 초기 온도/변화량	초기 상태·변화량의 추가 정보 확인
충전 조건 후보	First/Second C-rate, Switch SOC 및 조합	단일 조건보다 정책 전체를 봐야 함
제외	cell_id·batch ID·후기 knee·마지막 cycle·기록 길이	식별자/배치 의존 또는 미래 정보
결측 / 이상값	수명 결측은 학습 제외; IR=0 유지; 원본 보존	다른 운전 방식과 확인 대상의 범위를 기록

EDA 특성과 연결한 후보 모델

후보	선정 근거	확인할 약점
Random Forest 회귀 1차 후보	직선 하나로 표현하기 어려운 관계; 여러 트리를 합쳐 예측	긴 수명 과소 예측, 작은 표본의 과적합
Ridge 회귀 비교 기준	변수 수가 적고 log 수명 관계가 강함; 단순한 기준	직선 관계에서 벗어나는 구간
Gradient Boosting 회귀 후속 후보 / 미실험	추가 변수에서 비선형·조합 효과가 남으면 비교	깊이·학습률·트리 수 튜닝에 따른 과적합

현재 Random Forest 설정: 200개 트리, 최대 깊이 4, 말단 최소 3개 셀, random_state=42. 후보를 늘리는 것보다 단순 기준과 배치별 오차를 먼저 확인합니다. Gradient Boosting은 이 보고서에서 학습·평가하지 않았습니다.