

DAY 1 / MODEL DESIGN

배터리 수명 예측 EDA와 모델 설계 전략

울산캠퍼스 3반 | 최병준 | 2026.10.02

Batch1의 데이터 확인과 다섯 EDA 질문을 바탕으로 초기 100사이클의 정보에서 전체 수명을 예측하는 모델 전략을 세운다. 변수와 모델의 판단 근거는 Batch1만 사용한다.

선택 데이터	평가 데이터	관측 시점	Target
Batch1 / 46개 셀	Batch2 / 수명 확인 39개	100사이클 후	cycle_life / 사이클

핵심 판단

초기 신호	초기 $\Delta Q(V)$ 의 로그 분산은 수명과 $r=-0.886$ 이다. Q 급변 피크 지표는 관계가 약하고, knee는 후기 기록이 필요하므로 초기 입력에서 제외한다.
특성 선택	온도는 Tavg, 정책은 1단계 속도를 대표로 남긴다. 전환 SOC는 도메인 조합의 재료로 보존한다. 서로 겹치는 로그·충전 부담·발열 중 실제 열화 관측인 로그를 대표로 선택한다.
모델 전략	로그 L을 기준으로 평균 충전속도 E, 온도·부담 조합 T의 추가 효과를 Batch1 CV에서 확인한다. 선형회귀·Ridge·SVR·알은 나무·Random Forest를 같은 기준으로 비교한다.


데이터 범위와 단계

단계	확인하고 다음 단계로 넘길 판단
Data Check	Batch1의 구조·식별자·target-dummy·실제 cycle·공통 전압측 확인. 초기 정보와 최종 수명 정보 구분
EDA	Batch1 수명 분포, 네 가설, 정책·초기 측정값의 상관과 중복 판단
Feature Engineering	초기 100사이클에서 도메인 생성식 적용. 후보의 관계·중복을 확인하고 L·E·T 전달
Model Strategy	회귀 target, 그룹 분할, CV 내 전처리, 후보·파라미터·단순성 기준 설정

Batch2에는 단수명 셀이 많다는 분포 관찰만 남긴다. 조건별 수명·상관은 선정 근거에 사용하지 않는다. Batch3은 분석과 모델링에서 제외한다.

QUESTION 01 / CYCLE LIFE

수명 분포: 무엇을 구분할 수 있는가?



Batch1 표본	수명 범위	중앙값	단수명 / 장수명
46개 / 결측 0	534-1227사이클	858.5사이클	0 / 10개

확인한 내용과 해석

500사이클 미만 셀은 없고 1000사이클 초과 셀은 10개(21.7%)다. 나머지 36개는 중간 수명이다. IQR 기준 수명 이상치는 없다. 따라서 이 데이터에서 단수명 여부를 target으로 분류하면 유효한 두 집단을 만들 수 없다.

수명은 연속적인 차이가 있으므로 원래 사이클 단위의 cycle_life를 회귀 target으로 정한다. 단수명·장수명 경계는 EDA의 비교 기준으로만 사용한다.

가설 1: 운전조건으로 단수명을 구분할 수 있는가?

Batch1에는 단수명(<500사이클) 셀이 없어 단수명 여부를 충전 조건으로 분류하는 가설을 검증할 수 없다. 이 기준은 특성 선정에 사용하지 않는다. 충전속도와 전환 SOC의 연속적인 수명 관계는 Question 04에서 확인한다.

분포 관찰



Batch2에는 수명 확인 39개 중 단수명 28개가 있다. 이 관찰은 평가 범위의 차이를 이해하는 데 사용하며, Batch2의 조건별 관계로 입력이나 모델을 고르지 않는다.

설계로 연결

Batch1 전체에서 EDA와 후보 특성을 탐색한다. 모델·파라미터·입력 구성 비교는 학습 부분의 CV에서 수행하고 Hold-out은 고정 모델의 검증에 사용한다.

QUESTION 02 / DEGRADATION

열화곡선: knee를 초기 예측에 쓸 수 있는가?



확인한 내용

사이클별 방전용량 Qd는 감소하며 일부 구간에서 감소 기울기가 가팔라진다. 여러 smoothing window에서 위치가 안정적인 knee는 45/46개 셀에서 탐지됐다. Knee 시점과 수명은 Pearson $r=+0.827$, Spearman $\rho =+0.866$ 로 관련된다.

가설 3: 이른 knee로 짧은 수명을 구분할 수 있는가?

판단

수명과 관련성은 있지만 knee는 꺾임 이후의 기록을 포함해 찾은 값이다. 초기 100사이클 예측 시점에 알 수 있는 정보가 아니므로 입력에서 제외한다.

열화가 가속된 뒤의 knee는 상태 진단에는 의미가 있다. 이번 목적은 초기 관측으로 전체 수명을 예측하는 것이므로 관측 시점을 넘는 정보는 사용하지 않는다.

탐지 기준


100사이클부터 최종 수명까지의 Qd를 대상으로 window 11·21·41에서 평활화했다. 이어 붙인 두 직선이 단일 직선보다 오차를 10% 이상 줄이고, 뒤쪽 감소 기울기가 더 큰 경우를 탐색했다. 각 구간 50점 이상, window 간 knee 위치 차이 20사이클 이내를 안정 기준으로 삼았다.

사용할 정보	제외할 정보
초기 1-100사이클 평균 측정값	knee 시점과 knee 이후 기울기
10·100사이클의 같은 전압축 Q(V)	전체 기록 길이·최종 cycle 번호
실험 시작 시 정해진 충전 정책	cycle_life에서 파생한 입력

상관이 강하다는 사실만으로 초기 예측에 적합한 특성이 되지는 않는다. 계산 가능한 시점을 먼저 확인한다.

QUESTION 03 / EARLY $\Delta Q(V)$

초기 전압 곡선: 어떤 통계값을 남길 것인가?



가설 2: Q 급변 피크 크기·이동이 수명과 관련되는가?

2.7-3.4 V 구간의 cycle 10 피크 크기는 수명과 $r=-0.240$ ($p=0.109$), cycle 10→100 피크 전압 이동량은 $r=-0.226$ ($p=0.130$)이다. 단순회귀 R^2 는 각각 0.057, 0.051로 약해 현재 정의의 피크 지표는 제외한다.

가설 4: 초기 $\Delta Q(V)$ 로그 분산이 클수록 수명이 짧은가?

$\Delta Q(V)=Q_{100}(V)-Q_{10}(V)$ 를 공통 전압축 1000점에서 계산하고, 전압 위치별 변화의 분산에 $\log_{10}$ 을 취한다. 분산은 $ddof=0$ 으로 계산하며 target은 로그 변환하지 않는다.


유지 근거

수명과 Pearson $r=-0.886$, Spearman $\rho =-0.871$, 단순회귀 $R^2=0.785$ 다. 100사이클 시점에 계산 가능하고 초기 변화와 수명의 경향이 뚜렷하다.

세부 계산은 실제 cycle 번호로 10-100을 찾아 수행한다. 배열 위치를 cycle 번호로 간주하지 않고, 모든 셀의 전압축과 profile 행 수를 대조한다.

QUESTION 04 / CHARGING POLICY

충전 조건: 속도와 적용 구간을 함께 보자




정책 변수	수명 Pearson r	해석
1단계 C-rate	-0.580	충전속도와 수명의 음의 관계
전환 SOC	+0.235	단독 관계는 약하지만 속도와 적용 폭을 결합할 재료
2단계 C-rate	-0.096	한 단계의 속도만으로 전체 조건을 설명하기 어려움

정책별 표본 수가 적으므로 평균과 개별 셀을 함께 확인했다. 1단계 속도와 전환 SOC는 서로 $r=-0.854$ 로 겹친다. 수명과의 관계가 더 강한 1단계 속도를 직접 후보로 남기고 전환 SOC는 도메인 생성 재료로 보존한다.

도메인 연결 같은 속도라도 어느 SOC 구간에서 얼마나 충전했는지가 다르다면 부담이 다를 수 있다. C1·C2와 전환 SOC를 묶어 전체 부담, 단계별 부담, 이상적 평균 속도를 만든다.

QUESTION 05 / CORRELATION

상관관계: 겹치는 변수는 대표를 남긴다



위 상관계수는 Batch1의 정책, 초기 1-100사이클 평균값, 로그 분산, 수명으로 계산했다. 수명 전체의 평균값은 사용하지 않는다.

류음	근거	선택
온도	Tavg-Tmax r=0.956, Tavg-Tmin r=0.811. 수명 r: Tavg -0.482, Tmin -0.418, Tmax -0.404	Tavg 유지, Tmin-Tmax 직접 후보 제외
정책	1단계 속도-전환 SOC r=-0.854. 수명 r: 속도 -0.580, SOC +0.235	1단계 속도 유지, SOC는 생성 재료 보존

독립변수 간 상관 절댓값 0.8 이상을 중복 후보로 보고 수명과의 관계와 변수 역할로 대표를 골랐다. 기본 후보는 1·2단계 속도, 평균 QCharge·QDischarge·IR·Tavg·chargetime, 로그 지표의 8개다.

FEATURE ENGINEERING / DOMAIN

도메인 조합: 어떤 새 정보를 담는가?

s =전환 SOC/100, $Q_n=1.1$ Ah. C1은 전환 SOC까지, C2는 80%까지 적용되며 이후 1C 구간은 공통이다. 조합 지표는 0-80% 구간을 대상으로 한다.

후보	생성식	표현하려는 정보
L: 로그 분산	$\log_{10}(\text{var}(Q_{100}-Q_{10}))$	초기 전압별 열화 변화의 불균일성
F: 전체 충전 부담	$C1 \times s + C2 \times (0.8-s)$	전류 크기와 적용 SOC 폭의 결합
H: 저항 발열 근사	$\text{평균 } IR \times 1.1^2 \times F$	저항 성분의 발열 에너지 근사(Wh)
2단계 부담	$C2 \times (0.8-s)$	2단계 전류와 그 단계의 충전량
E: 이상적 평균 속도	$0.8 / [s/C1 + (0.8-s)/C2]$	이상적 정전류 충전시간의 관점
용량비	$\text{평균 } Q_{\text{Discharge}} / \text{평균 } Q_{\text{Charge}}$	넣은 전하 대비 회수한 전하의 비율
T: 온도·부담 조합	$(\text{평균 } T_{\text{avg}} - 30) \times F$	표면온도 편차와 정책 부담의 조합

생성식의 물리적 근거

정전류 단계에서 $I=C \times Q_n$, 시간=SOC 폭/C이다. 저항이 일정하다고 근사하면 $I^2 R dt$ 는 $R \times Q_n^2 \times C \times \text{SOC 폭}$ 으로 계산된다. 두 단계의 합이 F이며 저항을 반영하면 H가 된다. H는 실제 총발열 측정값이 아닌 저항 성분의 대리지표다.

큰 충전전류는 분극·물질 전달 부담과 흑연 음극의 리튬 도금 위험에 연결될 수 있다. 단일 C-rate보다 적용 구간을 함께 담는 지표를 검토한 이유다. E는 시간, T는 온도와 정책의 조합을 표현한다.


계산과 해석 범위

평균은 초기 100사이클에서 구하며 cycle 1의 공통 0 placeholder만 제외한다. 1.1 Ah와 30°C는 실험 조건의 상수이며 데이터에서 적합하지 않는다. 평균 표면온도를 충전 중 내부온도와 같다고 가정하지 않는다. 용량비 역시 정밀한 전하 손실량으로 단정하지 않는다.

근거: Severson et al. (2019), Methods; Measuring Irreversible Heat Generation (2022), Eq. 10; Onboard early detection and mitigation of lithium plating (2022). 상세 링크는 마지막 쪽과 README에 제시한다.

FEATURE SELECTION / BATCH1

관련성만큼 중복과 추가 정보를 확인한다



로그를 그린 이유는 원래 분산이 9.66×10^{-4} - 4.46×10^{-4} Ah²로 약 46.2배 차이 났기 때문이다. 로그는 작은 값이 몰리는 현상을 줄인다. 전압 곡선에는 큰 총용량 감소 이전의 활성물질 손실 등이 나타날 수 있어 초기 열화 신호로 해석한다.

후보	수명 r	선정 판단
로그 L	-0.886	실제 초기 열화 관측으로 대표 선택
전체 부담 F	-0.892	L과 r=0.952. 수명 관계 차이가 작고 중복이 커 직접 입력 제외
발열 H	-0.824	L과 r=0.883, F와 r=0.947로 겹쳐 제외
2단계 부담	-0.223	관계가 약하고 1단계 속도와 r=0.848로 겹쳐 제외
평균 속도 E	-0.737	L과 r=0.786. 시간 관점의 추가 후보로 전달
용량비	+0.124	관계가 약하고 39/46개가 1 초과. 제외
온도·부담 T	-0.614	조합 후보. Tavg와 r=0.979이므로 동시 입력 제외

모델 전달 후보는 L·E·T다. L-E r=0.786, L-T r=0.610, E-T r=0.351이다. L / L+E / L+T / L+E+T 를 같은 Batch1 CV에서 비교해 추가 정보가 없으면 제외한다.

수명과의 단독 관계가 강한 변수를 모두 넣지 않는다. 도메인 의미와 실제 예측 추가 효과를 각각 확인한다. 상관만 열화 원인을 확정하는 근거가 아니다.

MODEL STRATEGY / REGRESSION

Batch1 CV로 변수와 회귀 모델을 선택한다

목표는 초기 100사이클의 정보로 전체 수명을 예측하는 회귀다. Target은 원래 단위 cycle_life다. 셀당 한 행을 만들고 후기 knee·기록 길이·식별자는 입력하지 않는다.

모델 후보	EDA 특성과 연결한 선택 이유
선형회귀	로그의 뚜렷한 직선 경향. 단순한 회귀식과 계수 해석
Ridge	E 등 추가 후보와 L의 상관이 남으면 L2 규제로 큰 계수를 억제
얇은 의사결정나무	구간에 따라 달라지는 수명 관계 확인
SVR(RBF)	선형식으로 놓칠 수 있는 매끄러운 곡선 관계 확인
Random Forest	나무의 구간·조합 관계를 평균해 확인

분할·전처리·선정 순서

① Batch1의 수치형 충전 프로토콜을 그룹으로 묶어 GroupShuffleSplit(20%, seed=42)으로 학습 35개·Hold-out 11개 분리. ② 학습 안의 동일한 5-fold GroupKFold에서 네 변수 구성과 모델을 비교. ③ Pipeline의 scaler는 각 fold train만 fit. ④ 선정 파일과 모델을 저장한 뒤 Hold-out-Batch2 평가.

후보별 파라미터는 CV 평균 MAPE 최소값으로 선택한다. 전체 최소 MAPE에 그 후보의 fold 표본 표준오차를 더한 범위에서 변수 수, 모델 단순성, fold 편차, 평균 오차 순으로 고른다. 단순성 순서는 선형회귀→Ridge→얇은 나무→SVR→Random Forest다. Hold-out-Batch2 점수로 모델을 바꾸지 않는다.

파라미터 범위: Ridge $\alpha = 0.001-100$ (6개); 나무 깊이 2·3·4, 최소 잎 3·5; SVR C=100·1000·10000, $\epsilon = 10-50$, $\gamma = \text{scale} \cdot 0.1$; RF 100개 나무, 깊이 2·4·무제한, 최소 잎 2·4. 난수가 있는 단계는 42로 고정한다.

성능 보고와 재현

Train CV·Valid Hold-out·Test Batch2 MAPE와 세 Gap(Valid-Train, Test-Valid, Test-9.1)을 보고한다. MAE·RMSE·편향도 확인한다. 모델·규칙·파라미터·분할·실제 버전·입력 해시를 기록하며 Batch3은 평가하지 않는다.

참고 자료

Severson et al. (2019), Nature Energy | 저항 발열 근사 (2022) | 리튬 도금 (2022) | 쿨롱 효율 (2015).

분석 근거: Batch1 Data Check·EDA·Feature Engineering 노트북과 processed 입력. 실제 모델 비교·평가 결과는 DAY 2 README에 작성한다. 작은 표본의 관계를 요약한 설계이며 인과를 확정하지 않는다.