

DAY 1 / MODEL DESIGN

배터리 수명 예측 EDA와 모델 설계 전략

울산캠퍼스 3반 | 최병준 | 2026.10.02

MIT-Stanford LFP/흑연 배터리 데이터의 Batch1 + Batch2 + Batch3를 비교한다. 다섯 EDA 질문에서 확인한 관찰을 피쳐 선택과 회귀 모델 설계로 연결한다.

전체 데이터	EDA 대상	모델 입력	예측 시점
139개 셀	129개 셀	123개 셀 / 3개 변수	100사이클 관측 후

선택한 문제와 핵심 결론

최초 100사이클의 정보로 전체 수명 cycle_life를 사이클 단위로 예측하는 회귀를 선택한다. 최종 입력은 초기 $\Delta Q(V)$ 분산의 로그 지표, 전체 충전 부담, 저항 발열 근사다. 주모델은 Ridge 회귀로 설계한다.

EDA 핵심	Batch2의 단수명은 특정 운전 그룹에 집중된다. 후기 knee는 수명과 관련되지만 초기 예측에 낮다. 초기 로그 지표는 세 배치 모두 수명과 음의 관계를 보인다.
모델 선택	세 지표는 열화 관측, 충전 정책, 저항을 반영한 부담을 각각 표현한다. 일부 정보가 겹치는 점을 고려해 계수를 안정시키는 Ridge를 선택한다. 변수 개수만으로 선택하지 않는다.

데이터 범위와 단계별 역할

Batch	전체 / 수명 확인	수명 결측
Batch1	46 / 46	0
Batch2	47 / 39	8
Batch3	46 / 44	2

단계	담당 내용
Data Check	원본 구조·자료형·키·결측·placeholder를 확인하고 processed 데이터를 추출
EDA	수명 분포·열화·초기 곡선·충전 정책·상관관계를 비교하고 선택 근거를 정리
Feature Engineering	초기 100사이클 기준 생성식과 변수 제거를 적용하고 모델 입력표 저장

분석 단위는 셀 한 개이며 (batch, cell_id)로 식별한다. 수명 결측 10개는 EDA의 수명 비교에서 제외한다. 모델 입력에서는 초기 IR 평균이 0인 6개 셀을 추가로 제외한다. 이 보고서는 모델 학습 전의 설계 결과이며 학습·평가 점수를 제시하지 않는다.

EDA / QUESTION 01

Cycle Life 분포는 어떻게 생겼는가?




그림 1. 동일한 150~2300사이클 범위의 히스토그램. 점선은 배치 중앙값이며 실제 관측 범위는 392~1935사이클이다.




그림 2. 수명 확인 셀을 분모로 한 단수명(<500), 중간(500~1000), 장수명(>1000) 비율.

Batch / n	중앙값	관측 범위	단수명	장수명
batch1 / 46	858.5	534~1227	0개 / 0.0%	10개 / 21.7%
batch2 / 39	472.0	392~1186	28개 / 71.8%	3개 / 7.7%
batch3 / 44	1005.5	541~1935	0개 / 0.0%	23개 / 52.3%

관찰과 해석

단수명 28개가 모두 Batch2에 있고 해당 배치의 71.8%를 차지한다. Batch1·3에는 500사이클 미만 셀이 없다. Batch2의 중앙값은 472사이클로 가장 낮고, Batch3은 장수명 비율이 52.3%로 가장 높다.

가장 짧은 셀은 Batch2 cell 20(392사이클, 6C(60%)-3C)이다. Batch2 Base 30개 중 28개가 단수명인 반면 Newstructure 9개에는 단수명이 없어, 짧은 수명은 개별 극단값보다 운전 그룹과 연결된 분포 차이로 보인다. 수명이 짧다는 이유만으로 셀을 제거하지 않는다.

설계 반영

단수명/장수명 경계는 EDA 비교에 사용한다. 예측 목표는 연속적인 수명 값으로 두고, 학습·평가 분할에서는 배치별 구성과 오차를 함께 확인한다.

EDA / QUESTION 02

방전 용량은 일정하게 감소하는가?




그림 3. Q10으로 정규화한 셀별 방전 용량. 흐린 선은 모든 수명 확인 셀, 굵은 선은 배치 중앙 수명에 가까운 대표 셀의 21점 이동 중앙값, 점선은 대표 셀의 knee 후보다. 세로축은 0.76~1.08로 확대했다.




그림 4. 안정적으로 탐지된 knee 후보 127개와 최종 수명. 전체 Pearson $r=0.975$.

Batch	안정 후보 / 확인 셀	knee 중앙 시점
batch1	45 / 46	633.8사이클
batch2	38 / 39	360.6사이클
batch3	44 / 44	826.9사이클

관찰과 해석

초반의 완만한 변화 뒤 후반에 용량 감소가 빨라지는 구간이 관찰된다. knee 중앙 시점은 Batch1 약 634, Batch2 약 361, Batch3 약 827사이클로, Batch2에서 열화 가속이 더 일찍 나타난다.

방법: 100사이클 이후에 두 직선을 이어 적합했다. 구간당 최소 50개 관측값, 단일 직선 대비 오차 10% 이상 감소, 뒤 구간의 더 빠른 감소를 요구했다. 11·21·41점 중앙값에서 후보가 모두 나오고 시점 차이가 20사이클 이내인 셀만 비교했다.

설계 반영

knee는 수명과 강한 관계가 있지만 꺾임 이후 기록까지 보고 찾은 후기 지표다. 초기 100사이클 예측 입력에는 knee·마지막 cycle·전체 기록 길이를 넣지 않는다.

EDA / QUESTION 03

초기 $\Delta Q(V)$ 에서 차이가 보이는가?

$\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$. 공통 1000점 전압축(3.5~2.0 V)에서 비교한다. 용량 차이 곡선이며 미분 곡선 dQ/dV 와 구분한다.




그림 5. 장수명과 단수명 그룹의 $\Delta Q(V)$ 중앙 곡선 및 사분위 범위. Batch1·3에는 단수명 셀이 없어 장수명만 표시했다. Batch2 장수명 3개다.




그림 6. 같은 셀을 원래 분산 축과 log10 분산 축에서 비교했다. 분산은 약 103배($7.96 \times 10^{-6} \sim 8.21 \times 10^{-4} \text{ Ah}^2$) 차이 나므로 로그가 셀 간 차이를 읽기 쉽게 한다.

전체 / Batch	로그 지표-수명 Pearson r
All	-0.851
batch1	-0.886
batch2	-0.902
batch3	-0.702

관찰과 해석

초기 곡선 차이의 분산이 큰 셀일수록 수명이 짧은 경향이 세 배치 모두에서 유지된다. 전체 Spearman도 -0.892로 음의 관계다. 이 분산은 총용량 감소뿐 아니라 전압별 곡선 변화의 불균일성을 표현한다. [1]

도메인 해석: LFP/흑연 셀의 음극 활성물질 손실은 총용량 감소가 뚜렷해지기 전에도 전압 곡선을 바꿀 수 있다. 이 손실이 쌓이면 리튬을 받아들일 용량이 줄어 도급과 빠른 용량 감소로 이어질 수 있어, 초기 곡선 변화가 최종 수명과 연결될 가능성이 있다. [1]

설계 반영

$\log_{10}(\text{var}(\Delta Q(V)))$ 를 초기 열화 신호로 유지한다. 지표만 로그 변환하고 target cycle_life는 원래 사이클 단위를 유지한다.

EDA / QUESTION 04

충전 조건과 수명은 어떻게 연결되는가?




그림 7. Batch2의 동일 숫자 정책 3개에서 Base/Newstructure 평균 수명을 비교했다. 그룹은 정책명에 따른 구분이며 실제 물리 구조 변경을 뜻한다고 단정하지 않는다.




그림 8. 1단계 C-rate 단독의 수명 관계. 배치별 Pearson은 -0.580 / +0.191 / -0.083으로 방향과 크기가 달랐다.

관찰과 해석

공통 정책 3개에서 Base/Newstructure 평균 수명은 각각 약 484/872, 478/962, 449/991사이클이었다. 같은 숫자 충전 조건에서도 수명이 달라, 고속 충전 한 값만으로 수명을 설명하기 어렵다. Batch2의 운전 그룹 기준도 Batch1·3에 공통 적용하기 어렵다.

배치별 정책 평균 수명의 최저·최고를 비교했다. 오른쪽은 1단계 C-rate와 후기 열화 속도의 상관이다.

Batch	최저 평균 수명 정책	최고 평균 수명 정책	C1-후기 열화 속도 r
batch1	5.4C(80%)-5.4C · Base 546.5사이클 (n=2)	4C(80%)-4C · Base 1226.5사이클 (n=2)	+0.542 (n=45)
batch2	3.6C(9%)-5C · Base 394.5사이클 (n=2)	5.6C(26%)-4.5C · New 991.3사이클 (n=3)	+0.112 (n=38)
batch3	3.7C(31%)-5.9C · New 660.0사이클 (n=3)	4.8C(80%)-4.8C · New 1564.2사이클 (n=6)	+0.458 (n=44)

열화 속도는 안정 knee 이후 적합선의 용량 감소 기울기 크기(Ah/사이클)다. Batch1·3에서 더 큰 전류와 더 빠른 후기 감소가 관련됐지만, 이는 수명 전체를 본 진단 결과이며 초기 입력으로 사용하지 않는다.

설계 반영

C-rate와 적용 SOC 폭을 함께 묶어 충전 부담을 만든다. 공통 0~80% 정책 구간을 사용하며, 전류 단독 지표의 배치별 차이를 조합 변수에서 다시 확인한다.

EDA / QUESTION 05

어떤 신호가 수명과 관련되고 중복되는가?




그림 9. 기존 정책-초기 100사이클 평균 측정값-로그 지표의 Pearson 상관. 왼쪽은 변수 간 전체 행렬, 오른쪽은 수명과의 전체-배치별 관계다. IR=0은 기존 변수 EDA에서는 유지했다.

관찰과 해석

로그 지표가 수명과 가장 강하고 배치별로 일관된 음의 관계를 보인다. 방전 용량 평균은 전체 $r=-0.500$ 이지만 배치별로 $+0.193/-0.332/+0.217$ 로 방향이 달랐다. 온도와 충전시간도 전체 상관만으로 공통 효과를 판단하기 어렵다.

중복 후보	EDA에서의 판단
Tavg-Tmax $r=0.880$ Tavg-Tmin $r=0.859$	온도 후보는 Tmin을 대표로 남김. 수명과의 $ r $ 가 Tmin 0.332, Tavg 0.238, Tmax 0.017로 Tmin이 가장 큼
Tmax-Tmin $r=0.574$	Tmax는 Tmin과 높은 상관만으로 제거한 것이 아니라, 온도 묶음에서 수명과의 관계가 가장 약하다는 판단을 함께 사용

이는 도메인 조합을 만들기 위한 기본 후보 정리다. 최종 모델에는 개별 온도 값 대신 선정한 세 지표를 사용한다.

설계 반영

최종 123개 셀에서 로그-충전 부담 $r=0.558$, 로그-발열 $r=0.685$, 충전 부담-발열 $r=0.726$ 이다. 0.8 이상인 쌍은 없지만 일부 정보가 겹친다. 심각한 다중공선성으로 단정하지 않고 Ridge의 계수 안정화 목적과 연결한다.

FEATURE ENGINEERING / DOMAIN

세 지표에 어떤 정보를 담을 것인가?

최종 입력	생성식	의미
L: 로그 지표	$\log_{10}(\text{var}(Q_{100} - Q_{10}))$	초기 전압별 곡선 변화의 불균일성
F: 전체 충전 부담	$C1 \times s + C2 \times (0.8 - s)$	속도와 적용 SOC 폭을 결합한 정책 부담
H: 저항 발열 근사	$\text{평균 IR} \times 1.1^2 \times F$	내부저항을 반영한 0~80% 저항 발열 근사

s=전환 SOC/100, C1·C2=각 단계 C-rate, 공칭 용량 $Q_n=1.1$ Ah. 기존 측정값은 첫 사이클의 일괄 0 placeholder를 제외한 초기 100 사이클 평균이다. [1]

생성식의 도메인 근거

정전류 단계에서 $I=C \times Q_n$, 시간=SOC 폭/C이므로, 저항이 일정하다고 근사하면 $I^2 R dt = R \times Q_n^2 \times C \times \text{SOC 폭}$ 이다. 두 단계의 항을 합한 F는 전류 크기와 충전량을 함께 표현하고, H는 같은 정책에서도 셀 저항이 다를 때 부담이 달라지는 점을 반영한다. H는 실제 총발열을 측정한 값이 아니라 저항 성분의 대리지표다. [2]




그림 10. 전체 충전 부담(윗줄)과 저항 발열 근사(아랫줄)의 배치별 수명 관계. 발열은 양의 초기 IR이 있는 123개 셀을 사용했다.

전체 충전 부담은 세 배치 모두 음의 관계이며 전체 $r=-0.356$ 이다. 발열 근사는 전체 $r=-0.526$ 이고 Batch1·2에서 관계가 뚜렷하지만 Batch3에서는 거의 없다. 발열은 물리적 의미를 가진 검토 변수로 남기고, 배치3의 약한 관계도 결과에 함께 기록한다.

최종 선택

후보 6개 중 로그 지표·전체 충전 부담·저항 발열 근사를 최종 입력으로 선택한다. 2단계 부담은 대안 후보로 남긴다. 용량비는 관계가 약하고, 온도 교호작용은 Tmin과 $r=0.999$ 로 겹쳐 제외한다.

MODELING STRATEGY / TARGET & MODEL

회귀와 Ridge를 선택한 판단 기준

Regression을 선택하는 이유와 Target Variable

목표는 장수명/단수명 라벨이 아니라 배터리가 몇 사이클까지 유지되는지 설명·예측하는 것이다. 따라서 종속변수는 cycle_life이며 원래 사이클 단위를 사용한다. EDA의 129개 셀에서 단수명 28개와 장수명 36개만 분류하면 중간 수명 65개의 차이를 활용하지 못한다.

하나의 식에 세 입력을 동시에 사용

$$\text{예측 수명} = b_0 + b_1 \times L + b_2 \times F + b_3 \times H$$

학습할 때 L·F·H를 표준화하고 세 지표를 동시에 고려해 계수를 구한다. 각 지표의 단독 상관계수를 그대로 계수로 넣지 않는다. 위 식은 설계한 형태이며 현재 학습된 계수는 없다.

Ridge를 주모델로 선택하는 이유

로그 지표에서 직선 경향이 관찰됐고, 세 지표의 역할을 계수로 설명하기 쉬워 선형 모델을 출발점으로 삼는다. F와 H는 생성식 일부를 공유하고 $r=0.726$ 으로 관련돼 있다. Ridge는 계수가 과도하게 커지는 것을 억제해, 겹치는 정보가 있는 입력을 함께 사용할 때 계수의 안정성을 확보하려는 선택이다. [3]

$$\text{Ridge 학습 기준} = \text{예측 오차의 제곱합} + \alpha \times (b_1^2 + b_2^2 + b_3^2)$$

α 가 클수록 계수를 더 강하게 억제한다. 변수 3개 또는 표본 123개라는 숫자만으로 Ridge를 선택한 것은 아니다. 다중공선성이 심각하다는 결론도 아니다. 규제 없는 선형회귀를 기준으로 두고 선택 목적에 맞는지 확인한다.

EDA 특성과 연결한 후보 모델

후보 모델	데이터 특성과 연결한 판단	역할
선형회귀	로그 지표의 직선 경향과 세 변수의 계수 해석	규제 없는 기준
Ridge 회귀	입력 간 일부 중복을 고려한 계수 안정화	선택한 주모델
SVR (RBF)	직선으로 설명되지 않는 곡선 관계가 남는 경우	비선형 비교 후보
의사결정나무 회귀	특정 값에서 수명이 달라지는 구간 규칙 탐색	얇은 트리 비교 후보
Random Forest / Gradient Boosting	변수 간 비선형 조합과 구간별 관계 검토	앙상블 비교 후보

SVR·나무·앙상블도 회귀에 사용할 수 있다. 변수 수가 적다는 이유로 제외하지 않으며, 본 보고서의 핵심은 성능 순위 확정보다 선택 기준과 EDA의 연결이다. [4]

MODELING STRATEGY / DATA & VALIDATION

데이터 처리와 검증을 어떻게 설계할 것인가?

처리 항목	설계와 이유
관측 범위	정책 + cycle 1~100의 초기 측정값 + cycle 10/ 100 profile. 후기 knee-전체 기록 길이 등은 제외
셀과 식별자	한 행=한 셀. (batch, cell_id)로 병합 검증. 식별자와 Batch ID는 최종 모델 입력에서 제외
결측 / 이상값	수명 결측 10개 제외. 초기 IR=0인 6개는 실제 무저항으로 해석하지 않고 발열 계산 제외. 짧은 수명 자체로는 제거하지 않음
입력표	123개 셀: Batch1 46, Batch2 33, Batch3 44. L-F-H 3개와 target cycle_life 저장
학습 / 평가 분리	Batch 비율을 유지한 80:20 분할, random_state=42. 선택·튜닝은 학습 데이터 안에서 수행
표준화 / 규제	각 변수 단위가 달라 StandardScaler를 학습 데이터에만 맞춤. Ridge α 는 학습 구간 5-fold에서 작은 후보군으로 검토
확인 방법	같은 123개 셀에서 L 단독 $\rightarrow$ L+F $\rightarrow$ L+F+H 비교. MAE(사이클)를 기본 지표로, RMSE와 배치별 오차를 함께 확인
배치 차이 검토	추가로 한 Batch를 남기는 검증을 검토. Batch2 단수명은 다른 Batch에 없어 별도 배치 평가에서의 차이를 함께 해석

EDA 가설에서 모델 설계로 이어진 결론

발견한 가설	초기 예측에서의 결정
Batch2 운전 그룹의 단수명 구분	다른 Batch에 같은 기준 적용이 어려워 공통 초기 분류 지표로 기각
Q 급변 구간의 피크 크기·이동	수명 관계가 약하거나 배치별 방향이 달라 기각
이른 knee와 짧은 수명	연관은 강하지만 후기 기록을 사용하므로 초기 입력에서 기각
초기 $\Delta Q(V)$ 로그 분산	세 Batch에서 일관된 음의 관계로 유지

간단한 확인 사항: 상관관계만으로 열화 원인을 확정하지 않는다. 발열 근사의 Batch3 관계는 약하다. 세 지표의 추가 설명력과 Ridge 계수는 모델 학습 후 확인한다.

근거 자료

- (1) Severson et al. (2019), Nature Energy: 데이터·충전 정책·초기 $\Delta Q(V)$. [원 논문](#)
- (2) Measuring Irreversible Heat Generation (2022), JES, Eq. 10: I^2R 발열 근거. [논문](#)
- (3) scikit-learn: 선형회귀·Ridge의 규제 목적. [공식 문서](#)
- (4) scikit-learn 후보 모델: [SVR](#) / [의사결정나무](#) / [앙상블](#).

분석 근거: 01-01b Data Check, 02 EDA, 03 Feature Engineering 및 processed 데이터. 본 보고서의 표본 수와 상관계수는 현재 데이터에서 재계산했고 최종 입력표와 대조했다.